Πανεπιστήμιο Ιωαννίνων Ανάκτηση Πληροφορίας

Τμήμα Μηχανικών Η/Υ & Πληροφορικής Ακαδημαϊκό Έτος 2023-2024

Μηχανή αναζήτησης εγγράφων - Φάση 2η

Εμμανουηλιδης Εμμανουήλ – 4669

1) ΣΥΛΛΟΓΗ ΕΓΓΡΑΦΩΝ

Για τη συλλογή των εγγράφων επέλεξα να χρησιμοποιήσω ένα έτοιμο dataset σε μορφή .csv από από την online κοινότητα data science του Kaggle.
Συγκεκριμένα επέλεξα το papers.csv από το οποίο χρησιμοποιώ τα πεδία source id, year, title, abstract και full text.

2) ΤΡΟΠΟΠΟΙΗΣΗ ΑΡΧΕΙΟΥ

Για την απαραίτητη επεξεργασία του αρχείου δημιούργησα ένα python αρχείο με το όνομα scrapper το οποίο διαβάζει το .csv και για κάθε έγγραφο δημιουργεί και ένα διαφορετικό .txt αρχείο με τις πληροφορίες του εγγράφου.
Με μια σταθερά N καθορίζω το πόσα αρχεία εγγράφων θα δημιουργηθούν από τον scrapper.

3) ΚΑΤΑΣΚΕΥΗ ΕΥΡΕΤΗΡΙΟΥ

Για να μπορέσω να «διαβάσουμε» και να αναλύσω τα αρχεία που παρήγαγε ο scrapper δημιούργησα την κλάση Indexer.

Η παραπάνω κλάση υλοποιεί έναν ευρετήριο για αρχεία κειμένου χρησιμοποιώντας τη Lucene.

Αρχικοποίηση Indexer - Αρχικά, δημιουργείται ένας Indexer με τη χρήση ενός directory όπου θα αποθηκευτεί το ευρετήριο και ενός άλλου που περιέχει το path των αρχείων που θα ευρετηριαστούν.

Δημιουργία ευρετηρίου - Μέσω της μεθόδου createIndexer( ), ο indexer δημιουργεί το ευρετήριο και εκτελεί τις παρακάτω δράσεις

- Διαγραφή υπάρχοντος ευρετηρίου για να ξεκινήσει ένα νέο index.

- Ανάκτηση όλων των αρχείων από το path που έχει οριστεί και επιλογή μόνο των .txt αρχείων.

- Για κάθε αρχείο, δημιουργείται ένα νέο έγγραφο (Document) στο ευρετήριο. Το περιεχόμενο του αρχείου διαβάζεται και αποθηκεύεται σε ένα πεδίο του εγγράφου, ενώ οι σχετικές πληροφορίες των επιμέρους πεδίων του εγγράφου όπως ο τίτλος, η χρονολογία, η περίληψη κτλ. αποθηκεύονται σε επιμέρους αντίστοιχα πεδία.

Πιο αναλυτικά τα πεδια που χρησιμοποιούνται είναι τα ακόλουθα.

- contents όπου αποθηκεύεται όλο το περιεχόμενου του εγγράφου.

-source id όπου αποθηκεύεται ο αριθμός μητρώου του εγγράφου.

-year όπου αποθηκεύεται ο αριθμός που εχει γραφτει το έγγραφο.

- title όπου αποθηκεύεται ο τίτλος του εγγράφου.

- abstract όπου αποθηκεύεται μια σύντομη περιληψη του εγγράφου.

- appears όπου αποθηκεύεται το album όπου ανήκει το τραγούδι.

-full text id όπου αποθηκεύεται όλο το επιστημονικό έγγραφο.

Τέλος το δημιουργηθέν έγγραφο προστίθεται στο ευρετήριο.

Στο σημείο αυτό να σημειωθεί ότι με την κλάσης LuceneConsts ορίζω τα ονόματα των προαναφερθέντων πεδίων.

Αποθήκευση και κλείσιμο ευρετηρίου - Αφού ολοκληρωθεί η διαδικασία του indexing για όλα τα αρχεία, το ευρετήριο αποθηκεύεται με την εντολή writer.commit( ), ενώ ο indexer και το directory τερματίζουν με τις εντολές writer.close( ) και dir.close( ) αντίστοιχα.

Επιστροφή αποτελέσματος - Τέλος, η μέθοδος createIndexer( ) επιστρέφει τον αριθμό των εγγράφων που έχουν προστεθεί στο ευρετήριο, ώστε να γίνεται έλεγχος για την επιτυχή ολοκλήρωση της διαδικασίας ευρετηρίασης.

4) ΑΝΑΛΥΣΗ ΚΕΙΜΕΝΟΥ

Για την ανάλυση του κειμένου επέλεξα την κλάση StandardAnalyzer καθώς θεώρησα πως παρέχει μια ισορροπημένη προσέγγιση ανάλυσης και δεν εισάγει πολλές εξειδικευμένες παραμέτρους.

Η κλάση StandardAnalyzer εφαρμόζει μια σειρά από κανόνες επεξεργασίας του κειμένου, που περιλαμβάνουν την διαίρεση του κειμένου σε λέξεις (tokenization) με βάση τα κενά, την μετατροπή όλων των χαρακτήρων σε πεζά (lowercasing) και την αφαίρεση συμβόλων στίξης και συνημμένων σημείων (punctuation removal) γεγονός το οποίο τον καθιστά ιδανική περίπτωση για τις ανάγκες αυτής της εφαρμογής.

5) ΑΝΑΖΗΤΗΣΗ

Η αναζήτηση γίνεται με την κλάση Searcher η οποία διαβάζει το ευρετήριο από το δίσκο και με χρήση της μεθόδου search επιστρέφει τη λίστα με τα documents που αντιστοιχούν στην ερώτηση του χρήστη.

Κατά την αρχικοποίηση ενός αντικειμένου Searcher, δημιουργείται ένας IndexSearcher και ένας IndexReader για την περάτωση της αναζήτησης.

Η κλάση χρησιμοποιεί τους QueryParser που ορίζονται για κάθε πεδίο καθώς και για ολόκληρο το έγγραφο για να μετατρέψει τις αναζητήσεις σε αντικείμενα Query, τα οποία μπορούν να χρησιμοποιηθούν για την αναζήτηση στο ευρετήριο.

Οι QueryParser χρησιμοποιούν τον StandardAnalyzer για την ανάλυση των αναζητητικών ερωτημάτων.

Η μέθοδος search δέχεται ένα searchQuery και ένα field με βάση το οποίο θα γίνει η αναζήτηση.

Ανάλογα με το πεδίο που ορίζει ο χρήστης, επιλέγεται ο κατάλληλος QueryParser για τη μετατροπή του ερωτήματος σε Query αντικείμενο. Εφόσον ο χρήστης δεν επιλέξει πεδίο η αναζήτηση γίνεται σε ολόκληρο το έγγραφο με χρήση του αντίστοιχου QueryParser.

Στη συνέχεια, ο IndexSearcher εκτελεί την αναζήτηση και επιστρέφει έναν πίνακα ScoreDoc με τα αποτελέσματα.

Κάθε αποτέλεσμα αποθηκεύεται σε ένα αντικείμενο Document και προστίθεται στη λίστα resultDocs

6) ΠΑΡΟΥΣΙΑΣΗ ΤΩΝ ΑΠΟΤΕΛΕΣΜΑΤΩΝ

Τα αποτελέσματα της αναζήτησης παρουσιάζονται ανα 10 (δέκα) στον χρήστη, με τα πιο σχετικά αποτελέσματα να εμφανίζονται πρώτα βάσει της συναφειας τους με το ερώτημα που τέθηκε.

Εφόσον τα αποτελέσματα της αναζήτησης είναι αριθμός μεγαλύτερος του 10 (δέκα) στην αρχική του UI που έχουμε υλοποιήσει εμφανίζονται μόνο οι δέκα πρώτες επιλογές. Εφόσον ο χρήστης επιθυμεί να δει και τις υπόλοιπες πρέπει να πατήσει το κουμπί “NEXT 10” όπου θα του παρουσιάζει τα υπόλοιπα αποτελέσματα ανα 10. Το κουμπί αφαιρείται από το UI εφόσον δεν υπάρχουν άλλα αποτελέσματα προς εμφάνιση.

Επίσης, ο χρήστης έχει την δυνατότητα να κατηγοριοποιήσει τα αποτελέσματα της αναζήτησης ανάλογα με το πεδίο σε αύξουσα σειρά πατώντας το κουμπί “ORDER BY”. Εφόσον το πεδίο προς κατηγοριοποίηση παραμείνει κενό το κουμπί “ORDER BY” δεν έχει καμία λειτουργία.

Επιπρόσθετα το application διατηρεί τις 10 (δέκα) κορυφαίες αναζητήσεις με βάση τη συχνότητα, χρησιμοποιώντας ένα ιστορικό των αναζητήσεων.

Το ιστορικό αποθηκεύεται σε ένα αρχείο με το όνομα "search-history.txt" στον δίσκο. Πιο συγκεκριμένα, όταν ο χρήστης πατάει το κουμπί "Search", το πρόγραμμα ανοίγει το αρχείο και καταγράφει το ερώτημα που έχει εισαχθεί από τον χρήστη.

Αν το ερώτημα έχει ήδη εγγραφή στο αρχείο, αυξάνουμε τον αριθμό εμφανίσεων του ερωτήματος στο Map που χρησιμοποιούμαι για την διατήρησει των εν λόγω αποτελεσμάτων. Το Map είναι της μορφής <ερώτημα, αριθμός εμφανίσεων του ερωτήματος>.

Εφόσον το ερώτημα είναι νέο δημιουργούμε μια νεα εγγραφή στο Map με το ερώτημα και τον αριθμό 1 (ενα) ως αριθμό εμφανίσεων του ερωτήματος.

Εάν ο χρήστης κάνει double click σε ένα από τα αποτελέσματα της ερώτησης του, δημιουργείται και ανοίγει ένα νέο παράθυρο με τίτλο τον τίτλο του εγγράφου και περιεχόμενο της πληροφορίες του.

7) ΧΡΗΣΗ ΤΗΣ ΕΦΑΡΜΟΓΗΣ

Αρχικά, πρέπει να γίνει εκτέλεση του scrapper για να διαβαστούν και τροποποιηθούν τα δεδομένα από το αρχείο .csv ώστε να είναι έτοιμα προς ευρετηριοποίηση, ανάλυση και αναζήτηση. Η εκτέλεση του scrapper γίνεται με την εντολή ***python3 scrapper.py*** στο directory όπου βρίσκεται το python αρχείο.

Ο αριθμός των τραγουδιών που θα διαβαστούν ορίζεται από την σταθερά N η οποία για τον παραδοτέο κώδικα έχει αρχικοποιηθεί στην τιμή 20.

Ωστόσο, έχουμε τη δυνατότητα να ορίσουμε τον αριθμό του N σε οποιαδήποτε θετική ακέραια τιμή μέχρι και το 500 όπου είναι ο μέγιστος αριθμός τραγουδιών που υπάρχουν στο .csv αρχείο.

Στη συνέχεια, για την επεξεργασία των αρχείων, εκτελώ την IndexStart. Όπου όταν ολοκληρώνεται επιτυχώς παίρνω ένα output της μορφής:

```
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Bit-Serial Neural Networks.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Connectivity Versus Entropy.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Ensemble' Boltzmann Units have Collective Computational Properties like
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Hierarchical Learning Control - An Approach with Neuron-Like Associativ
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\How Neural Nets Work.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Introduction to a System for Implementing Neural Net Connections on SIM
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Invariant Object Recognition Using a Distributed Associative Memory.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\LEARNING BY STATE RECURRENCE DETECTION.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Learning on a General Network.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Learning Representations by Recirculation.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Microelectronic Implementations of Connectionist Neural Networks.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Neural Net and Traditional Classifiers.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Neuromorphic Networks Based on Sparse Optical Orthogonal Codes.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\On Properties of Networks of Neuron-Like Elements.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\On Tropistic Processing and Its Applications.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Optimal Neural Spike Classification.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\PATTERN CLASS DEGENERACY IN AN UNRESTRICTED STORAGE DENSITY MEMORY.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Presynaptic Neural Information Processing.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\REFLEXIVE ASSOCIATIVE MEMORIES.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Scaling Properties of Coarse-Coded Symbol Memories.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Speech Recognition Experiments with Perceptrons.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Stability Results for Neural Networks.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Strategies for Teaching Layered Networks Classification Tasks.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\Synchronization in Neural Nets.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\The Hopfield Model with Multi-Level Neurons.txt
Indexing: C:\Users\emmanuel\Desktop\uni\Anaktisi Plhroforias\InformationFinal\src\main\resources\files2\The Performance of Convex Set Projection Based Neural Networks.txt
Indexed files: 31
```

Τότε τερματίζω αυτό το configuration και τρέχω την InformationFinalApplicationApp όπου θα εμφανίσει ένα παράθυρο με την μηχανή αναζήτησης.

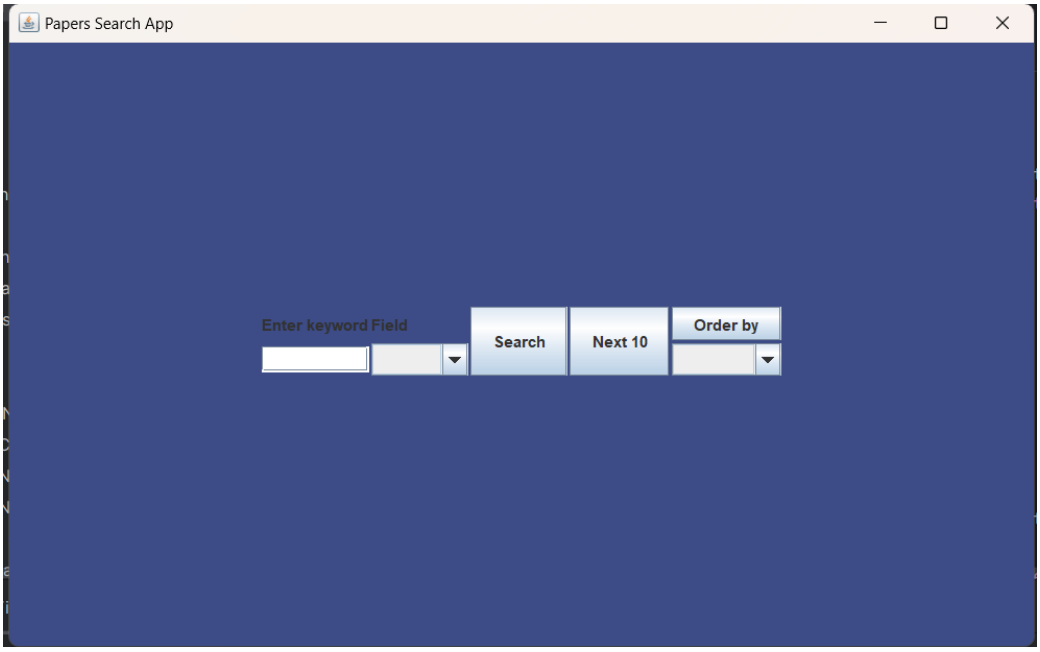

Για αναζήτηση του keyword **is** σε όλο το περιεχόμενο των αρχείων (αφήνοντας κενή την επιλογή πεδίου) η εφαρμογή παράγει τα ακόλουθα αποτελέσματα

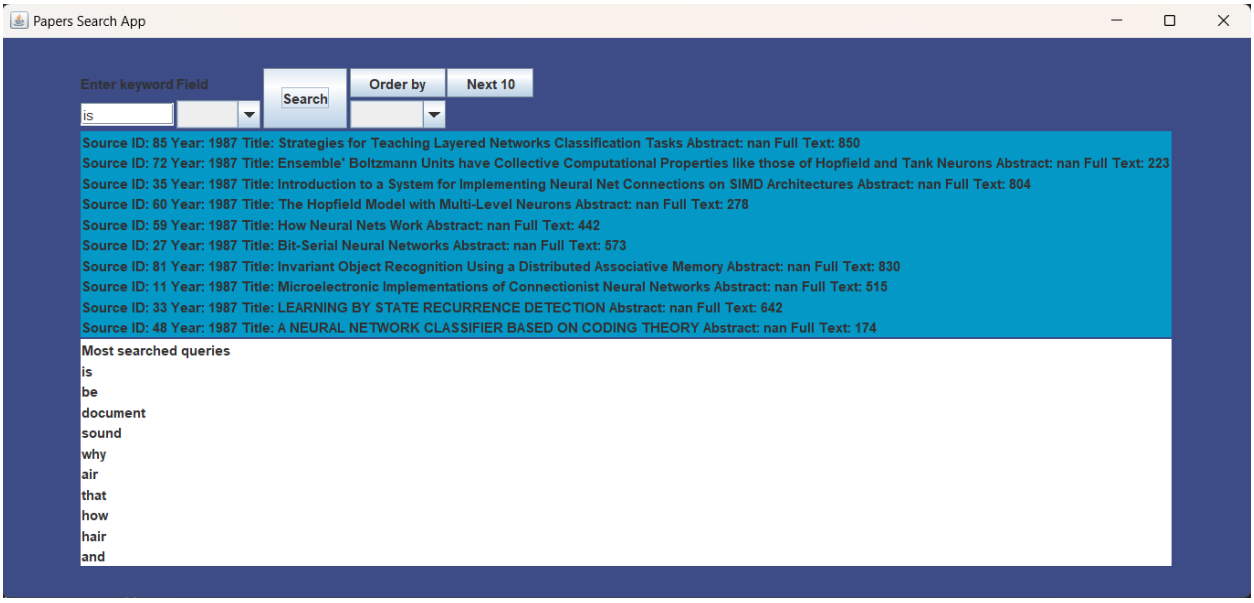

Όπως μπορείτε να δείτε ο όρος is είναι ο πιο συχνά αναζητήσιμος όρος και το πιο σχετικό paper με αυτόν το keyword είναι το Strategies for Teaching Layered Networks Classification Tasks στο οποίο αν κάνουμε double click μπορούμε να δούμε όλες τις πληροφορίες του :

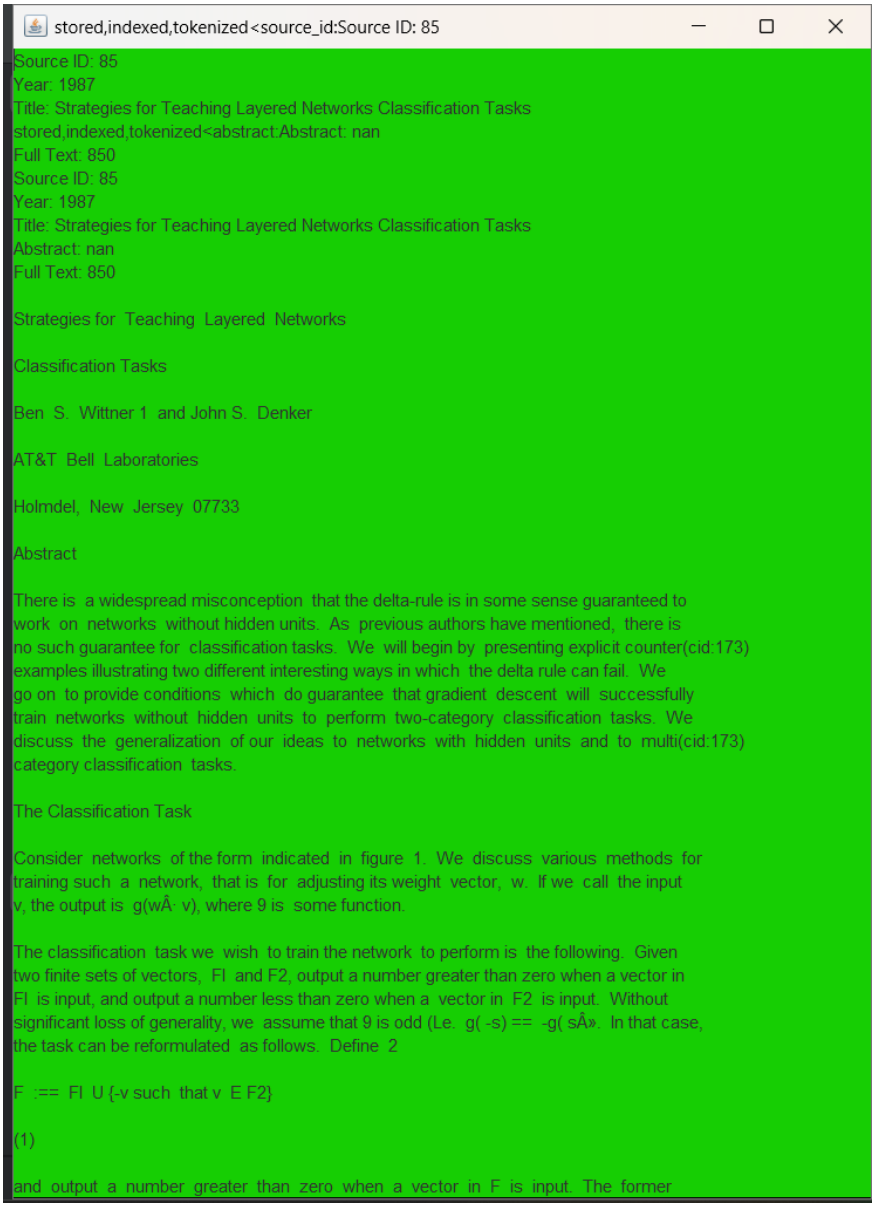

8) ΣΧΟΛΙΑ

Ο σύνδεσμος για το github της εργασίας είναι ο άκολουθος
https://github.com/emmemman/Information-Retrieval